

На правах рукописи

Ефименко Богдан Эдуардович

**ФИЛОГЕНЕТИЧЕСКИЙ ПОДХОД К ВОССТАНОВЛЕНИЮ И АНАЛИЗУ
МУТАЦИОННЫХ СПЕКТРОВ КОДИРУЮЩИХ
ПОСЛЕДОВАТЕЛЬНОСТЕЙ НА ВИРУСАХ И МИТОХОНДРИАЛЬНЫХ
ГЕНОМАХ ПОЗВОНОЧНЫХ**

1.5.8. – Математическая биология, биоинформатика

Автореферат
диссертации на соискание учёной степени
кандидата биологических наук

Калининград – 2026

Работа выполнена в Центре геномных исследований Федерального государственного автономного образовательного учреждения высшего образования «Балтийский федеральный университет имени Иммануила Канта».

Научный руководитель:	Гунбин Константин Владимирович , кандидат биологических наук
Научный консультант:	Попадьин Константин Юрьевич , кандидат биологических наук
Официальные оппоненты:	Алёшин Владимир Вениаминович , доктор биологических наук, Московский государственный университет имени М.В. Ломоносова, Научно-исследовательский институт физико-химической биологии имени А. Н. Белозерского, заведующий отделом эволюционной биохимии Иванков Дмитрий Николаевич , кандидат физико-математических наук, Сколковский институт науки и технологий, Центр био- и медицинских технологий, старший преподаватель
Ведущая организация:	Федеральное государственное бюджетное научное учреждение «Федеральный исследовательский центр Институт цитологии и генетики Сибирского отделения Российской академии наук» (ИЦиГ СО РАН)

Защита диссертации состоится 18 мая 2026 г. в 15:00 на заседании диссертационного совета 24.1.101.01 при Федеральном государственном бюджетном учреждении науки Институте проблем передачи информации им. А.А. Харкевича Российской академии наук (ИППИ РАН) по адресу: 127051, г. Москва, ГСП-4, Большой Каретный переулок, д. 19, стр. 1.

С текстом автореферата и диссертации можно ознакомиться в библиотеке ИППИ РАН, а также на сайте ИППИ РАН по адресу: http://iitp.ru/upload/content/1752/EB_dissertation.pdf

Автореферат разослан «____» _____ 2026 г.

Ученый секретарь

диссертационного совета 24.1.101.01

доктор биологических наук

Казенников Олег Васильевич

Общая характеристика работы

Актуальность исследования. Изучение закономерностей мутационного процесса является фундаментальной задачей эволюционной биологии. Мутационные спектры (распределения частот различных типов нуклеотидных замещений в определенных нуклеотидных контекстах) служат ключом к пониманию механизмов повреждения и репарации ДНК, а также позволяют реконструировать изменчивость мутационного процесса видов. В эпоху геномики критически важно точное разграничение нейтрального мутагенеза и давления естественного отбора, особенно при анализе патогенов (вирусов) и маркеров старения (мтДНК).

Несмотря на признанную значимость, существующие методы реконструкции мутационных спектров, опирающиеся на сравнение с консенсусной последовательностью или референсным геномом, имеют существенные ограничения. Они игнорируют топологию филогенетических деревьев и промежуточные замены на внутренних ветвях (гомоплазии), что приводит к потере информации и искажению данных при межвидовых сравнениях. В условиях экспоненциального роста доступных последовательностей в базах данных (GenBank) актуальна разработка и валидация точных филогенетических подходов для реконструкции спектров.

Особую актуальность представляет применение таких подходов к митохондриальной ДНК (мтДНК) позвоночных и РНК-содержащим вирусам. Мутагенез мтДНК, протекающий в условиях высокой окислительной нагрузки и специфической репликации, изучен недостаточно за пределами человека и модельных организмов. Для РНК-вирусов точная оценка нейтрального спектра необходима для прогнозирования эволюции антигенных свойств и лекарственной устойчивости.

Степень разработанности темы исследования. Наибольший прогресс в анализе мутационных спектров достигнут для соматических мутаций в ядерном геноме человека, что привело к созданию каталогов мутационных подписей (COSMIC и Signal) и прорывам в онкогеномике (Л. Александров, П. Кэмпбелл и

др.). Однако мутационные профили зародышевой линии немодельных организмов изучены фрагментарно. Связь между нуклеотидными спектрами и эволюцией аминокислотного состава белков известна, но количественные модели, разделяющие вклад мутационного давления и отбора, нуждаются в совершенствовании.

В то же время, в области вирусной геномики и митохондриальной генетики дефицит универсальных биоинформатических инструментов, учитывающих филогению, существенно сдерживает проведение масштабных сравнительных исследований. Существующие работы, как правило, сосредоточены на узком наборе модельных видов, что затрудняет выявление глобальных эволюционных трендов. Особую актуальность приобретает проблема масштабного сравнительного анализа мутационных профилей немодельных позвоночных и оценки влияния геномной архитектуры РНК-вирусов на их мутационные процессы с применением унифицированных биоинформатических подходов.

Цель исследования: выявить фундаментальные особенности мутационных спектров РНК-содержащих вирусов и митохондриальных генов позвоночных, а также оценить влияние мутационного смещения на эволюцию белковых последовательностей.

Задачи исследования:

1. Разработать биоинформатический метод для восстановления мутационных спектров на основе филогенетического подхода и подтвердить его надежность.
2. Реконструировать и провести сравнительный анализ мутационных спектров белок-кодирующих генов мтДНК широкого круга позвоночных и РНК-содержащих вирусов.
3. Оценить вклад различных факторов мутагенеза в формирование мутационных спектров мтДНК и РНК-содержащих вирусов.
4. Количественно оценить вклад почти нейтрального мутационного спектра в изменение аминокислотного состава белков в ходе эволюции.

Научная новизна. Разработан и реализован в виде общедоступного веб-сервиса уникальный программный конвейер NeMu (nemu-pipeline.com), позволяющий с высокой точностью реконструировать мутационные спектры для любых групп организмов, используя филогенетическую информацию, в том числе вероятности предковых состояний. Впервые на примере подтипа позвоночных (*Vertebrata*) показано, что мутационные спектры мтДНК формируются под воздействием дефицита активности систем репарации (BER и MMR) и асимметрии цепей при репликации. Выявлены фундаментальные сходства механизмов мутагенеза РНК-вирусов, оказывающие разнонаправленное влияние на эволюцию белков вирусов с положительной и отрицательной цепью, что обусловлено различной локализацией генов на цепях РНК. Разработана предиктивная модель, показывающая, что направление эволюции переменных сайтов белков более чем на 50% предопределено мутационным давлением.

Теоретическая значимость работы состоит в углублении и расширении существующих представлений о молекулярной эволюции. В рамках исследования было доказано доминирование внутренних факторов мутагенеза (репликация, репарация) над внешними для мтДНК и вирусов. Выдвинуто предположение, что причиной влияния экологических и морфофизиологических факторов на мтДНК является дефицит репарационных систем. Обоснована преимущественно нейтральная эволюция переменных сайтов белков.

Практическая значимость состоит в создании инструментария (NeMu), применимого для решения задач анализа гетерогенности мутационного процесса в геноме и эпидемиологического надзора. Разработанная модель аминокислотных замен может быть использована для прогнозирования эволюции вирусных белков (в т.ч. SARS-CoV-2) при разработке вакцин и для получения штаммов-продуцентов в биотехнологии, позволяя предсказывать вероятные «мутационные траектории» организмов.

Методы исследования. В работе использован комплекс методов биоинформатики и математической биологии: филогенетический анализ (реконструкция деревьев и предковых состояний методом максимального

правдоподобия, IQ-TREE), методы матричного разложения для выделения мутационных подписей (NNLS, SigProfilerAssignment), статистическое моделирование и анализ данных (Python).

Основные положения, выносимые на защиту:

1. Разработанный филогенетический подход к реконструкции мутационных спектров обеспечивает статистически достоверное восстановление частот замещений, превосходя стандартные консенсусные методы за счет учета длин ветвей, рекуррентных мутаций и вероятностной оценки предковых нуклеотидов.

2. Мутационный профиль мтДНК позвоночных формируется на основе трех основных факторов: спонтанного дезаминирования ДНК в одноцепочечном состоянии, окислительного повреждения и дефицита систем репарации оснований (BER) и репарации ошибочно спаренных нуклеотидов (MMR).

3. Фундаментальные процессы мутагенеза у РНК-вирусов, вероятно, являются сходными и характеризуются универсальным смещением в сторону транзиций, однако направление эволюции вирусных белков определяется полярностью генома: расположение кодирующих последовательностей преимущественно на положительной цепи РНК приводит к трансформации мутационного смещения (например, у вирусов с отрицательной цепью) и, как следствие, к различным траекториям белковой эволюции.

4. Частоты аминокислотных замен в переменных сайтах белков вирусов и мтДНК могут быть спрогнозированы исключительно на основе нуклеотидного мутационного спектра (с точностью $R^2 > 0.5$), что доказывает определяющую роль специфического мутационного смещения в формировании направлений белковой эволюции наряду с естественным отбором.

Апробация результатов диссертации. Результаты работы были представлены на международных конференциях Mitochondria'22, SMBE Everywhere'22, SMBE'24 и российских конференциях OpenBio'23, ХимБиоSeasons'24, MCCMB'25.

Основное содержание работы

Глава 1. Литературный обзор

Литературный обзор посвящен анализу современных подходов к восстановлению мутационных спектров и их роли в изучении молекулярной эволюции. Проведен систематический анализ источников данных для реконструкции спектров: от коллинга соматических мутаций в онкологии (проекты TCGA, PCAWG) и трио-секвенирования до филогенетических методов. Подробно рассмотрены механизмы мутагенеза в митохондриальной ДНК (мтДНК) позвоночных, включая влияние асинхронной репликации и окислительного стресса. Отдельное внимание уделено особенностям мутационных процессов у РНК-содержащих вирусов (в частности, влиянию полярности генома и ферментов организма-хозяина APOBEC и ADAR) и существующим проблемам в разграничении вклада нейтрального мутагенеза и естественного отбора в эволюцию белковых последовательностей. В заключении главы сформулирована основная проблема: отсутствие универсальных биоинформатических инструментов для филогенетически корректного восстановления спектров у немодельных организмов и вирусов, что препятствует пониманию фундаментальных эволюционных закономерностей.

Глава 2. Материалы и методы

Разработка алгоритма реконструкции мутационных спектров. Для восстановления профиля почти нейтральных нуклеотидных замен на основе филогенетических данных был разработан программный конвейер NeMu¹ на языке Nextflow (Рисунок 1). Алгоритм конвейера включает автоматический сбор последовательностей из базы данных (например, Genbank NT) и последующий филогенетический анализ (Таблица 1). Ключевой особенностью метода является вероятностный подход к аннотации мутаций, учитывающий неопределенность реконструкции на различных ветвях филогенетического дерева.

¹ Веб-сервер доступен по ссылке <https://nemu-pipeline.com/>




Рисунок 1 – Схема программного конвейера NeMu.

Таблица 1 – Алгоритм NeMu.

Шаг	Программы	Описание
0	–	Входные данные: белок, название вида и база данных
1	TBLASTN	Сбор данных: Автоматическое получение ортологичных последовательностей и внешних групп из баз данных GenBank или MIDORI2
2	MACSE, MAFFT, SeqKit, Galign	Множественное выравнивание с учетом рамки считывания и его фильтрация
3	IQ-TREE 2	Построение филогенетического дерева методом максимального правдоподобия (GTR+F0+G6+I)
4	Treeshrink	Удаление длинных ветвей на дереве (артефакты автоматического сбора данных)
5	Newick tools	Контроль качества внешней группы и укоренение дерева
6	IQ-TREE 2	Восстановление предковых последовательностей на основе дерева и выравнивания, а также категоризация сайтов по скоростям замен
7	PyMutSpec ²	Сбор мутаций с дерева, их аннотация и получение мутационного спектра с поправкой на тринуклеотидный контекст и вероятность мутаций

² Библиотека на Python для анализа спектров, разработанная в рамках работы над диссертацией (<https://pypi.org/project/PyMutSpec/>)

Валидация метода и симуляционные эксперименты. Оценка точности разработанного алгоритма проводилась с помощью эволюционных симуляций последовательностей (модуль AliSim в IQ-TREE 2). Были смоделированы наборы данных, имитирующие внутривидовую изменчивость (модели замен GTR и RY12.12, деревья большие и малые, корневая последовательность случайная и реальный CYTB человека) и межвидовую дивергенцию (на основе дерева 4705 млекопитающих и аналогичных параметрах модели и последовательности корня дерева). Сравнение реконструированных спектров с симулированными проводилось с использованием метрик косинусного сходства. Дополнительно NeMu сравнивался с классическим методом восстановления спектров, основанным на консенсусной последовательности. Также, полученные спектры сравнивались с известными в литературных данных.

Характеристика объектов исследования. Материалом для работы послужили нуклеотидные последовательности мтДНК и РНК-вирусов из открытых баз данных:

1. мтДНК позвоночных: Из базы MIDORI2 отобраны последовательности 13 белок-кодирующих генов для 11 887 видов. Для углубленного анализа 192-компонентных спектров (учитывающих нуклеотидный контекст) использованы гены CYTB, ND2, CO1, CO3 представителей 5 классов (*Mammalia*, *Actinopteri*, *Aves*, *Lepidosauria*, *Amphibia*), прошедшие фильтрацию по качеству и количеству мутаций.

2. Митохондриальный геном человека: Проанализирована выборка из 49570 полных геномов (современных и древних), для которых была построена высокоточная филогения. Для сравнения использовались данные по соматическим мутациям из базы TCMA³.

3. РНК-содержащие вирусы: Сформирована выборка белок-кодирующих генов или полипротеинов для 30 видов вирусов (более 500 последовательностей на вид), включая семейства *Coronaviridae*, *Orthomyxoviridae*, *Flaviviridae* и др.

³ <https://tcma.drbioright.org/tcma/mutation.html>

Отдельно проанализирован массив из более чем 5,6 млн аннотированных мутаций SARS-CoV-2 для 24 отдельных клад вируса.

Выбор перечисленных объектов обусловлен их высокой скоростью мутирования и представленностью в базах данных.

Анализ мутационных подписей. Декомпозиция спектров на мутационные подписи проводилась с использованием инструмента SigProfilerAssignment и базы данных COSMIC v3.3. Для корректного сопоставления спектры мтДНК были трансформированы в 96-компонентный формат с учетом асимметрии цепей (условное разделение на тяжелую и легкую цепи) и ренормализованы на тринуклеотидный состав генома человека.

Моделирование эволюции белков. Для оценки влияния мутационного спектра на эволюцию белков была применена линейная предсказательная модель. Она рассчитывает ожидаемые частоты аминокислотных замен (ϕ) на основе матрицы генетического кода (A) и вектора нуклеотидного мутационного спектра (μ) согласно уравнению $A\mu = \phi$. Качество прогноза оценивалось с помощью коэффициента детерминации (R^2). Валидация модели проводилась путем сравнения прогнозируемых частот с реальными частотами замен в сайтах белков вирусов и митохондрий, в том числе с использованием марковских цепей (CTMC) для моделирования эволюционных траекторий SARS-CoV-2.

Глава 3. Результаты и обсуждение

3.1. Полученные в исследовании данные

Для валидации разработанного метода и последующего сравнительного анализа были оценены мутационные спектры белок-кодирующих генов мтДНК и вирусов. Набор данных мтДНК включает 2866 видо- и ген-специфических 192-компонентных спектров для 4 генов 5 классов позвоночных. Этот набор данных был получен в результате фильтрации по следующим параметрам: длина выравнивания, количество последовательностей, соотношение транзиций к трансверсиям и количество реконструированных мутаций. Кроме того, восстановлены 111 117 мутаций для полной мтДНК человека, что позволило

определить мутационные спектры для каждого гена. Также, были получены 12-компонентные мутационные спектры 30 РНК-содержащих вирусов, относящихся к трем группам: вирусы с положительной цепью (оцРНК(+)), с отрицательной цепью (оцРНК(-)) и двуцепочечные (дцРНК).

3.2. Валидация и эффективность NeMu

Следующим этапом работы стала верификация разработанного конвейера NeMu. Для подтверждения точности филогенетического подхода была проведена серия симуляционных экспериментов, имитирующих эволюцию последовательностей с известными параметрами мутагенеза. Сравнение спектров, восстановленных с помощью NeMu, с «истинными» (симулированными) спектрами показало высокую точность реконструкции: медианное косинусное сходство превысило 0.95 для всех вариантов параметров (Рисунок 2А).




Рисунок 2 – Валидация конвейера NeMu. (А) Точность восстановления мутационных спектров на случайных деревьях. Сравнение смоделированных и восстановленных 192-компонентных мутационных спектров на основе синонимичных мутаций. (Б) Сравнение косинусного сходства между спектрами, полученными с помощью NeMu и на основе консенсуса, с разницей между

нативным деревом и деревом-звездой. Дерево-звезда является базовым отражением связей между последовательностями и консенсусом

Сравнительный анализ с классическим подходом, основанным на консенсусной последовательности, выявил ключевое преимущество вероятностного метода. Консенсусный метод демонстрирует приемлемые результаты только на выборках с низкой дивергенцией. Однако на филогенетических деревьях с длинными ветвями или при высоких скоростях мутирования консенсусный подход систематически занижает количество рекуррентных мутаций (гомоплазий) и искажает спектр (Рисунок 2Б). Метод NeMu, использующий принцип неопределенности при реконструкции предковых состояний, корректно учитывает топологию дерева, что позволяет восстанавливать неискаженные спектры даже для быстро эволюционирующих объектов, таких как мтДНК и РНК-вирусы.

3.3. Закономерности мутагенеза мтДНК позвоночных

С использованием полученных мутационных спектров был проведен сравнительный анализ 192-компонентных мутационных спектров для представителей пяти классов позвоночных: *Mammalia*, *Actinopteri*, *Aves*, *Lepidosauria* и *Amphibia*.

Анализ выявил глобальный консервативный паттерн мутагенеза мтДНК:

1. Доминирование транзиций: Во всех таксонах наблюдается высокое соотношение транзиций к трансверсиям ($T_i/T_v > 9$ в среднем среди видов) (Рисунок 3).

2. Асимметрия цепей: На тяжелой цепи доминируют замены C>T и A>G. Предположительно, основными источниками этих мутаций являются спонтанное дезаминирование нуклеотидов в одноцепочечном состоянии, в котором тяжелая цепь находится в процессе асинхронной репликации мтДНК, и химическое повреждение, ассоциированное с внутриклеточным окислительным стрессом.

3. Сходство мутагенеза генов: Несмотря на наличие известного градиента мутаций в мтДНК, спектры для генов из различных регионов генома статистически неразличимы.




Рисунок 3 – Средний мутационный спектр гена CYTB на основе 1697 видов позвоночных животных для тяжелой цепи мтДНК. Буква «Н» в индексах нуклеотидов отражает тяжелую (Heavy) цепь.

Несмотря на общий паттерн, выявлены таксон-специфические особенности мутационных спектров:

1. Уникальное мутационное смещение у птиц (*Aves*): В отличие от холоднокровных, у птиц наблюдается экстремально высокая доля замен $A>G$ в спектре тяжелой цепи (Рисунок 4). Предположительно, этот феномен связан с физиологическими особенностями: высокие температура тела и уровень метаболизма у птиц усиливают окислительное дезаминирование аденина (превращение A в гипоксантин, который, спариваясь с C , приводит к $A>G$).

2. Дефицит репарации в мтДНК: Декомпозиция спектров на мутационные подписи позволила оценить два основных источника мутаций в мтДНК: (i) неэффективность системы эксцизионной репарации оснований (BER), преимущественно связанная с асимметричными мутациями $C>T$ (SBS30),

обусловленными низкой эффективностью NTHL1, и (ii) неэффективность системы репарации ошибочно спаренных нуклеотидов (MMR), в основном связанная с мутациями A>G (SBS12) (Рисунок 5). Выраженность подписей у разных классов отличается, что указывает либо на реорганизацию систем репарации мтДНК в процессе перехода к гомойотермии, либо на выраженное влияние метаболической активности или температуры тела на мутагенез мтДНК.




Рисунок 4 – Распределение частот транзиций в видовых спектрах позвоночных. Заливка вокруг линий отражает ошибку среднего (бутстреп, 1000 реплик).




Рисунок 5 – Распределение мутационных подписей в класс-специфичных спектрах гена Cytb, полученных с помощью SigProfilerAssignment. Показаны только 3 основных сигнатуры, к которым относится более 90% мутаций.

Использованный подход не позволил восстановить подпись полимеразы POLG. Учитывая, что мутации, связанные с POLG, будут симметричными, т.е. вносить основной вклад в спектр легкой цепи, мы можем предположить, что подпись POLG скрыта в подписи, связанной с дефицитом MMR (SBS12), или в SBS5. Предположительно, низкая эффективность репарации порождает глубокое влияние экологических и морфофизиологических признаков на мутагенез мтДНК, в результате чего мтДНК является высокочувствительным маркером для отслеживания разнообразных физиологических процессов и воздействий окружающей среды в разных видах животных.


Кроме того, избыточный набор восстановленных мутаций в мтДНК человека позволил: (i) подтвердить ранее обнаруженный градиент мутаций C>T и A>G на большой дуге тяжелой цепи мтДНК, связанный с асинхронным режимом репликации и различным временем пребывания участков мтДНК в одноцепочечном состоянии; (ii) выявить гетерогенность мутационных спектров в различных гаплогруппах человека, что свидетельствует об эволюции мутационных спектров мтДНК в популяции человека.

3.4. Влияние полярности генома на эволюцию РНК-вирусов

Анализ мутационных спектров 30 видов РНК-вирусов показал, что полярность генома – ключевой фактор их мутагенеза. Различные факторы (спонтанное дезаминирование, клеточные ферменты APOBEC и ADAR, окислительный стресс) вызывают в основном замены C>U и A>G в геномах вирусов (Рисунок 6). Однако их проявление в кодирующих последовательностях зависит от полярности генома:

1. оцРНК(+) вирусы (*Coronaviridae*, *Flaviviridae* и др.): Геномная РНК является матрицей. Мутации C>U фиксируются напрямую, что приводит к обеднению генома цитозином и, соответственно, кодонов, содержащих цитозин.
2. оцРНК(–) вирусы (*Orthomyxoviridae*, *Rhabdoviridae* и др.): Кодирующая цепь (+) комплементарна геномной. Мутации C>U на геномной (–)

цепи отображаются как G>A на (+) цепи, что приводит к обеднению кодонов гуанином.



(замещений в спектре) смещены относительно центра координат к (-0.3, 0.3); показаны только проекции признаков с наибольшим вкладом.

3.5. Влияние мутационных спектров на эволюцию белков

В заключительной части работы была проверена гипотеза о том, что нейтральный мутационный спектр способен предсказывать направление эволюции белков. Для этого была применена линейная модель, преобразующая вектор частот нуклеотидных мутаций в матрицу частот аминокислотных замен (Рисунок 7).




Рисунок 7 – Модель аминокислотных замен на основе мутационных спектров. А и Б – входные данные модели, В и Г – выходные. (А) Мутационный спектр SARS-CoV-2 (клада 20A). (Б) Таблица стандартного генетического кода с указанием основных мутационных «поток». Цветом условно отмечены аминокислоты, доля которых растет (красный) и убывает (синий) согласно отображенным «поток». (В) Ожидаемые частоты аминокислотных замен,

предсказанные моделью на основе спектра SARS-CoV-2 (клада 20A) и при допущении изначально равномерного использования кодонов. Серые столбы показывают общую потерю (слева) и приобретение (внизу) для каждой аминокислоты. (Г) Наблюдаемые во всем протеоме и предсказанные равновесные частоты аминокислот коронавируса.

Анализ показал высокую предсказательную силу модели. Во-первых, частоты наблюдаемых аминокислотных замен более чем на 50% ($R^2 > 0.5$) обусловлены исключительно структурой генетического кода и почти нейтральным мутационным спектром (Рисунок 8А). Это опровергает гипотезу о тотальном доминировании отбора в процессе формирования аминокислотного профиля белков. На более поздних кладах (после Омикрона) прогностическая сила значительно увеличилась (Рисунок 8Б), предположительно вследствие того, что измененный спектр (частота G>U снизилась примерно в 2 раза) был более типичным для SARS-CoV-2 (и других коронавирусов) и приводил к меньшему числу мутаций, подвергающихся фильтрации естественным отбором. Таким образом, предположительно произошла адаптация мутационного спектра.




Рисунок 8 – Сравнение реальных и предсказанных частот аминокислотных замен SARS-CoV-2. (А) Сравнение для клады 20А. График показан в логарифмических координатах. (Б) Качество прогноза для ранних (до Омикрона) и поздних клад.

Во-вторых, данная модель демонстрирует высокую прогностическую силу исключительно для мутаций в вариабельных сайтах белков, в то время как на консервативных сайтах прогноз не имеет смысла (Рисунок 9А). Также, прогноз имеет удовлетворительную точность только на мутациях, которые оказывают незначительное влияние на приспособленность вируса ($\Delta\text{fitness} \approx 0$) (Рисунок 9Б). Прогностическая сила снижается или исчезает для вредных и полезных мутаций, а также в консервативных сайтах, поскольку сильный очищающий или положительный отбор нивелирует исходный мутационный сигнал. Следует отметить, что модель демонстрирует низкую прогностическую способность в отношении частот замен в «горячих точках» мутагенеза, поскольку мутации в данных сайтах, как правило, способствуют увеличению приспособленности согласно полученным данным.




Рисунок 9 – Модель аминокислотных замен на разных категориях сайтов и мутаций. (А) Точность модели для различных клад в различных категориях скоростей сайтов, где категория 1 – самые медленно и 5 – самые быстро мутирующие сайты. Горизонтальная линия выделяет значение коэффициента детерминации, равное 0, ниже которого модель работает хуже, чем модель, предсказывающая среднюю частоту для всех замен. (Б) Точность прогнозирования аминокислотных замен для разных категорий мутаций согласно их $\Delta\text{fitness}$.

В-третьих, ретроспективный анализ аминокислотного состава SARS-CoV-2 в период пандемии COVID-19 подтвердил надежность предложенной модели. Эволюция вирусного протеома следовала траектории, предсказанной нейтральным спектром, что выражалось в обогащении генома U-содержащими кодонами, кодирующими гидрофобные аминокислоты, в частности лейцин и фенилаланин (Рисунок 10А). Аналогичный паттерн был выявлен при сравнении аминокислотного состава оцРНК(+) и оцРНК(-) вирусов: предсказанные различия, основанные на сопоставлении средних равновесных частот для групп, демонстрируют высокую корреляцию с наблюдаемыми (Рисунок 10Б). Таким образом, групп-специфический мутационный спектр определяет различные траектории эволюции вирусных белков. Аналогичные результаты получены на ген-специфичных спектрах мтДНК.




Рисунок 10 – Модель в рамках предсказания аминокислотного состава. (А) Прогнозирование изменений аминокислотного состава для SARS-CoV-2 за 5 лет с начала пандемии COVID-19 с помощью симуляции (корреляция Пирсона $r=0.57$, $p=0.01$, $n=20$). (Б) Прогнозирование отличий в аминокислотном составе белка RdRp оцРНК(+) и оцРНК(-) вирусов с помощью равновесных частот (корреляция Пирсона $r=0.78$, $p<10^{-4}$, $n=20$).

Наконец, установлено, что точность предсказания частот аминокислотных замен зависит от эволюционного масштаба, что продемонстрировано на примере генов мтДНК (Таблица 2). Максимальная прогностическая сила ($R^2 \approx 0.88$) достигается для соматических мутаций в раковых опухолях человека, где влияние естественного отбора минимально и есть только «мутационный шум». На уровне полиморфизмов точность снижается, поскольку отбираются только аллели, позволяющие популяциям существовать и развиваться. На межвидовом уровне точность снижается ($R^2 < 0.2$), поскольку сильный естественный отбор «размывает» первичный мутационный сигнал, сохраняя только функционально допустимые замены. Таким образом, прогнозирование частот аминокислотных замен и изменения аминокислотного состава доступно только на уровне полиморфизмов и соматических мутаций.

Таблица 2 – Качество прогноза аминокислотных замен на основе мутационных спектров. R^2 – коэффициент детерминации.

Уровень	Ген	R^2	R^2 (случайные спектры)	Кол-во замен
Сравнительно- видовой	CYTB	0.19	0.04	6296
	ND1	-0.09	-0.03	4885
Полиморфизмы	CYTB	0.27	-0.01	28761
	ND2	0.28	0.09	20722
	12 генов	0.49	0.14	20160
Соматические мутации	тяжелой цепи мтДНК	0.88	0.14	3382

Заключение

В диссертационной работе решена актуальная научная задача по разработке высокоточного биоинформатического метода реконструкции мутационных спектров и выявлению фундаментальных закономерностей молекулярной эволюции митохондриальных генов позвоночных и генов РНК-содержащих вирусов. Проведенное исследование связывает базовые биохимические процессы (репликация, репарация) с макроэволюционными трендами изменения белковых последовательностей.

Основным итогом работы стало создание универсального инструмента (программный конвейер NeMu), позволяющего перейти от описательного анализа отдельных мутаций к системному изучению мутационных процессов на филогенетическом масштабе. В работе впервые на массиве данных, включающем тысячи видов, продемонстрировано, что мутационный профиль мтДНК и РНК-вирусов формируется преимущественно эндогенными факторами: «асимметрией» репликации, ошибками полимераз и эффективностью систем репарации. Ключевым биологическим результатом стало доказательство того, что мутационный спектр является направляющей силой, которая предопределяет траекторию эволюции аминокислотного состава белков более чем на 50%, что было подтверждено на примере пандемической эволюции SARS-CoV-2. Кроме того, приведены обоснования гипотезы о постепенном адаптивном изменении мутационных спектров в эволюции видов на примере генома SARS-CoV-2 и частично мтДНК человека.

Достоверность полученных результатов обеспечивается масштабным анализом более 9000 последовательностей белок-кодирующих генов мтДНК 5000 видов позвоночных животных, а также анализом геномов 30 вида РНК-содержащих вирусов. Также, проведена тщательная валидация разработанного филогенетического алгоритма NeMu. Корректность работы алгоритма верифицирована серией симуляционных экспериментов, сопоставлением с существующими подходами восстановления спектров на основе консенсуса и сравнением с известными спектрами различных

организмов. Статистическая значимость выводов о влиянии мутационных спектров на эволюцию белков подтверждается высоким коэффициентом детерминации ($R^2 > 0.5$) при сравнении прогнозируемых моделью и реальных частот аминокислотных замен.

В работе впервые реализован подход к декомпозиции мутационного спектра мтДНК, позволивший выделить компоненты, ассоциированные с активностью конкретных систем репарации (BER и MMR), и связать их с эколого-физиологическими характеристиками организмов (температурой тела, метаболизмом) на примере классов позвоночных животных пандемической.

Теоретическая значимость исследования заключается в:

1. Уточнении фундаментальных механизмов мутагенеза мтДНК: Сравнительный анализ мутационных спектров у позвоночных продемонстрировал дефицит репарации в мтДНК. Выдвинуто предположение о том, что воздействие экологических и морфофизиологических факторов на мтДНК обусловлено недостаточной эффективностью репарационных систем.

2. Уточнении фундаментальных механизмов мутагенеза РНК-вирусов: Показано, что полярность генома РНК-вирусов является ключевым фактором, трансформирующим единое мутационное давление в противоположные наблюдаемые спектры замещений (+цепь: C>U; –цепь: G>A).

3. Уточнении механизма изменчивости консервативных белков: Количественно показано, как нуклеотидное мутационное смещение определяет направление эволюции белковых последовательностей, ограничивая адаптивные траектории, на краткосрочных и долгосрочных масштабах.

Практическая ценность работы подтверждается созданием общедоступного веб-сервера конвейера NeMu (nemu-pipeline.com), который может быть использован научным сообществом для решения прикладных задач:

1. Экологический мониторинг: NeMu позволяет сравнивать мутагенный фон популяций или видов из различных биотопов, выявляя скрытое воздействие факторов среды на мутагенез или факторы естественного отбора, специфические для отдельных сред обитания.

2. Эпидемиологическое прогнозирование: Разработанная модель аминокислотных замен применима для предсказания вероятных мутационных трендов патогенов (в т.ч. новых штаммов коронавирусов и гриппа), что важно для дизайна вакцин.

3. Биотехнология и белковый дизайн: Разработанная модель аминокислотных замен может быть использована для оценки вероятности получения штаммов-продуцентов с заданными свойствами путем симуляции эволюции белков в конкретном мутационном контексте.

Дальнейшее развитие темы состоит в применении разработанного инструментария для глубокого анализа молекулярной эволюции малоизученных групп организмов (насекомые, растения, вирусы, кишечнополостные и губки), исследования эволюции мутационных спектров, а также в интеграции модели аминокислотных замен с алгоритмами предсказания структуры белков (например, AlphaFold) для поиска функционально оптимальных вариантов белков в задачах фармацевтики и биотехнологии.

Выводы

1. Разработан и валидирован новый филогенетический метод (NeMu) для реконструкции мутационных спектров. Доказано, что предложенный подход, учитывающий длины ветвей и вероятности предковых состояний, обеспечивает значительно более высокую точность восстановления спектров по сравнению с традиционными методами, основанными на консенсусных последовательностях, особенно для быстро эволюционирующих генов и видов.

2. Получены и систематизированы мутационные спектры мтДНК для 5 классов позвоночных. На основе анализа генов мтДНК более 1600 видов выявлено, что мутационный процесс в митохондриях является эволюционно консервативным среди позвоночных и характеризуется доминированием транзиций C>T и A>G на тяжелой цепи. Установлено, что исключением являются птицы (*Aves*), чей спектр значимо обогащен заменами A>G, что ассоциировано с высоким уровнем метаболизма и окислительного стресса.

3. Определены ключевые факторы мутагенеза мтДНК. Посредством разложения 192-компонентных спектров на мутационные подписи установлено, что основными драйверами мутагенеза мтДНК позвоночных являются: (i) спонтанное дезаминирование в одноцепочечном состоянии в ходе асинхронной репликации; (ii) таксон-специфический дефицит систем репарации. Показано, что предполагаемая подпись дефицита репарации ошибочно спаренных нуклеотидов (MMR) более выражена у теплокровных животных.

4. Установлена роль полярности генома в формировании спектров РНК-вирусов. Сравнительный анализ 30 вирусов показал, что, несмотря на сходство базовых механизмов повреждения РНК, наблюдаемые мутационные спектры кодирующих цепей кардинально различаются в зависимости от полярности генома. Доказано, что для вирусов с положительной цепью характерно преобладание C>U замещений, тогда как для вирусов с отрицательной цепью – комплементарных G>A замещений, что определяет разнонаправленные траектории эволюции их белков.

5. Доказана определяющая роль мутационного давления в эволюции белков вирусов. Разработанная модель показала, что частоты аминокислотных замен в вариабельных сайтах белков объясняются нейтральным мутационным смещением ($R^2 > 0.5$), а не только давлением отбора. Напротив, «горячие точки» мутагенеза находятся под положительным отбором. Продемонстрировано, что в ходе пандемии COVID-19 эволюция протеома SARS-CoV-2 следовала траектории, прогнозируемой нейтральной моделью, направленной на обогащение генома U-содержащими кодонами. Кроме того, на примере коронавируса обнаружены паттерны адаптивного изменения мутационного спектра в рамках приспособления к новому организму-хозяину.

6. Выявлена зависимость предсказательной силы мутационного спектра от эволюционного масштаба на примере мтДНК позвоночных. Показано, что точность прогнозирования аминокислотных замен на основе спектра максимальна для соматических мутаций ($R^2 \approx 0.88$), снижается на уровне внутривидового полиморфизма и минимальна на межвидовом уровне ($R^2 < 0.2$).

Это свидетельствует о том, что соматические мутации наиболее точно отражают «чистый» мутационный спектр, тогда как на макроэволюционных масштабах эффект нейтрального мутагенеза маскируется действием очищающего отбора.

Список работ, опубликованных автором по теме диссертации

По теме диссертации опубликовано 4 статьи в международных рецензируемых научных журналах, входящих в основные библиометрические базы данных (PubMed, WoS и Scopus):

1. Mikhailova AG, Mikhailova AA, Ushakova K, Tretiakov EO, Iliushchenko D, Shamansky V, Lobanova V, Kozenkov I, **Efimenko B**, Yurchenko AA, Kozenkova E, Zdobnov EM, Makeev V, Yurov V, Tanaka M, Gostimskaya I, Fleischmann Z, Annis S, Franco M, Wasko K, Denisov S, Kunz WS, Knorre D, Mazunin I, Nikolaev S, Fellay J, Reymond A, Khrapko K, Gunbin K, Popadin K. A mitochondria-specific mutational signature of aging: increased rate of A > G substitutions on the heavy strand. *Nucleic Acids Res.* 2022 Oct 14;50(18):10264-10277. doi: 10.1093/nar/gkac779. PMID: 36130228; PMCID: PMC9561281.

2. **Efimenko B**, Popadin K, Gunbin K. NeMu: a comprehensive pipeline for accurate reconstruction of neutral mutation spectra from evolutionary data. *Nucleic Acids Res.* 2024 Jul 5;52(W1):W108-W115. doi: 10.1093/nar/gkae438. PMID: 38795067; PMCID: PMC11223800.

3. Iliushchenko D, **Efimenko B**, Mikhailova AG, Shamanskiy V, Saparbaev MK, Matkarimov BT, Mazunin I, Voronka A, Knorre D, Kunz WS, Kapranov P, Denisov S, Fellay J, Khrapko K, Gunbin K, Popadin K. Deciphering the Foundations of Mitochondrial Mutational Spectra: Replication-Driven and Damage-Induced Signatures Across Chordate Classes. *Mol Biol Evol.* 2025 Feb 3;42(2):msae261. doi: 10.1093/molbev/msae261. PMID: 39903101; PMCID: PMC11792237.

4. Lobanova V, Kozenkov I, Khaibulin E, Tatarkina M, **Efimenko B**, Skripetskaya V, Dzhigkaev AH, Krylova AS, Prokopenko AV, Toshchakov SV, Goncharov A, Popadin K, Gunbin K. Age-related dynamics of m.189A>G and

m.408T>A variants in skeletal muscle of an osteoarthritic Cohort: Connections to BMI and muscle strength. Mitochondrial Communications. 2025 Aug 5;3:66-78. doi: 10.1016/j.mitoco.2025.08.001. ISSN 2590-2792.

Кроме того, по теме исследования сделаны устные и постерные доклады на ведущих профильных международных и всероссийских научных конференциях:

1. SMBE Everywhere, 2022, онлайн, устный доклад «Mutational spectrum of SARS-CoV-2 shapes main patterns of nucleotide and amino acid evolution»;

2. workshop “Mitochondria 2022”, Эйн-Геди, Израиль, постерный доклад «The mitochondrial somatic mutational spectrum in human cancers is sensitive to the hypoxia level»;

3. OpenBio 2023, онлайн, постерный доклад «Реконструкция нейтральных мутационных спектров - NeMu пайплайн»;

4. ХимБиоSeasons 2024, Калининград, Россия, устный доклад «Восстановление нейтральных мутационных спектров на основе филогенетических данных»;

5. SMBE 2024, Пуэрто-Вальярта, Мексика, постерный доклад «NeMu: A Comprehensive Pipeline for Accurate Reconstruction of Neutral Mutation Spectra from Evolutionary Data»;

6. MCCMB 2025, Москва, Россия, устный доклад «Мутационный спектр объясняет свыше 60% наблюдаемых аминокислотных замен РНК-содержащих вирусов и митохондриальной ДНК».

Ефименко Богдан Эдуардович

**ФИЛОГЕНЕТИЧЕСКИЙ ПОДХОД К ВОССТАНОВЛЕНИЮ И АНАЛИЗУ
МУТАЦИОННЫХ СПЕКТРОВ КОДИРУЮЩИХ ПОСЛЕДОВАТЕЛЬНОСТЕЙ
НА ВИРУСАХ И МИТОХОНДРИАЛЬНЫХ ГЕНОМАХ ПОЗВОНОЧНЫХ**

Автореферат

диссертации на соискание учёной степени
кандидата биологических наук

Подписано в печать **XX.YY.2026** г.

Формат 60×90 1/16. Усл. печ. л. **1,5**

Тираж 100 экз. Заказ **21**

Отпечатано в Полиграфическом центре
Балтийского федерального университета им. И. Канта
236001, г. Калининград, ул. Гайдара, 6